
DEEP LEARNING

-


INPUT & PREPROCESSING

Grupp 6:

Milda Kopmane

Nadine Knoop

Henry Che



INTRODUKTION

- Fashion MNIST, ett dataset med 28x28 gråskalebilder av kläder.
- Målet är att bygga en klassificeringsmodell som kan avgöra vilken kategori ett plagg tillhör.

Fokusområde *Input & preprocessing*

- Det här området handlar om hur datan förbereds innan den används i modellen.
 - Vi kollar på skillnaden mellan olika sätt att mata in data i modellen.
 - Målet är att förstå hur datans format och kvalitet påverkar modellens inläring.
-

GRUNDMODELL

Vi använde en CNN-modell för bildklassificering.

Fashion MNIST-bilderna reshapes till formatet $(28, 28, 1)$ eftersom CNN-modeller behöver *tredimensionell* input med *höjd*, *bredd* och *kanal*.

Modellen innehåller:

- *Conv2D* - lager för att hitta visuella mönster
- *MaxPooling* för att minska bildstorleken
- *Flatten* för att omvandla feature maps till en vektor
- *Dense* - lager för klassificering

Modellen tränades på Fashion MNIST - bilder för att känna igen olika typer av kläder.

```
# Grundmodell med CNN

def create_model():

    model = keras.Sequential([
        layers.Input(shape=(28, 28, 1)),

        layers.Conv2D(32, (3,3),
                       activation='relu',
                       padding='same'),

        layers.MaxPooling2D((2,2)),

        layers.Conv2D(64, (3,3),
                       activation='relu',
                       padding='same'),

        layers.MaxPooling2D((2,2)),

        layers.Flatten(),

        layers.Dense(64, activation='relu'),

        layers.Dense(10, activation='softmax')
    ])

    model.compile(
        optimizer='adam',
        loss='sparse_categorical_crossentropy',
        metrics=['accuracy']
    )

    return model
```

VAD VI TESTADE

*Vi jämförde hur olika
preprocessing-metoder påverkade:*

- **Accuracy** – hur många bilder modellen klassificerade korrekt
- **Loss** – hur stora modellens fel var under träningen

Område	Experiment	Vad vi undersökte
Skalning	Normalisering	Pixelvärden 0–255 → 0–1
Skalning	Standardisering	Centrering kring medelvärdet
Informationsförlust	Låg upplösning	Minskad mängd bilddetaljer
Informationsförlust	Center Crop	Delar av bilden tas bort
Informationsförlust	Compression	Försämrad bildkvalitet
Generalisering	Weak augmentation	Små variationer i bilder
Generalisering	Strong augmentation	Kraftiga förändringar i bilder

NORMALISERING

Pixelvärden i Fashion MNIST går från:

0 = svart

255 = vitt


Normalisering betyder:

$$x_{norm} = \frac{x}{255}$$

så att alla värden hamnar mellan 0 och 1.

Fördelar:

- neurala nätverk tränas stabilare och snabbare
- gradient descent fungerar bättre
- mindre risk för stora vikter



Modell	Training Accuracy	Validation Accuracy	Overfitting
Baseline	0.9269	0.8908	Tydlig
Normalisering	0.9244	0.9117	Mindre

STANDARDISERING

Pixelvärdena centreras kring medelvärdet och skalas med hjälp av standardavvikelsen.

Standardisering görs med formeln:

$$x_{\text{standardiserad}} = (x - \text{mean}) / \text{std}$$



Effekten blir att:

- datan centreras kring 0
- spridningen skalas så att standardavvikelsen blir ungefär 1
- Pixelvärdena kan bli negativa och positiva.

Fördelar:

- jämnare fördelning av data
- kan ge stabilare träning
- kan minska skillnader mellan stora och små värden

Standardisering (mean/std)



Modell	Training Accuracy	Validation Accuracy	Overfitting
Baseline	0.9269	0.8908	Tydlig
Standardisering	0.9386	0.9145	Mindre

BILDAUGMENTERING

- Slumpmässiga justeringar visar hur mycket modellen förlitar sig på specifika attribut.
 - En modell som förlitar sig mindre på specifika särdrag förbättrar sin generaliseringsförmåga markant.
 - Vi kan till exempel beskära eller rotera ett foto för att minska modellens beroende av objektets exakta position.
 - Det finns många olika augmentationsmetoder som används inom deep learning idag.
 - I praktiken brukar man kombinera flera olika metoder för bildaugmentering samtidigt för bäst resultat.
-

LOW RESOLUTION

Bildernas upplösning minskades från 28x28 till 16x16 pixlar.


Detta gör att modellen får mindre bildinformation och färre detaljer att arbeta med.

Fördelar:


- mindre datamängd
- snabbare träning
- lägre minnesanvändning

Nackdelar:

- viktiga bilddetaljer kan försvinna
- sämre accuracy



Modell	Test Accuracy	Informationsförlust
Baseline	0.8836	Ingen
16x16 upplösning	0.8649	Viss



CENTER CROP

Bilderna beskars från 28x28 till 24x24 pixlar genom att kanterna togs bort.

Detta gör att modellen får mindre bildinformation att arbeta med.


Fördelar:

- mindre datamängd
- snabbare träning
- fokus på den centrala delen av bilden

Nackdelar:

- viktiga bilddetaljer kan försvinna
- delar av kläderna kan kapas bort
- sämre accuracy

Center Crop (24x24)




Modell	Test Accuracy	Informationsförlust
Baseline	0.8836	Ingen
Center Crop	0.8809	Liten

Original 28x28



Center Crop 24x24



COMPRESSION

Bilderna komprimerades med JPEG-kvalitet = 50.


Kompression minskar filstorleken men kan också försämma bildkvaliteten och ta bort viktiga detaljer.

Fördelar:


- mindre filstorlek
- snabbare lagring och överföring
- lägre minnesanvändning

Nackdelar:



- förlorad bildinformation
- suddigare bilder
- sämre accuracy



Modell	Test Accuracy	Informationsförlust
Baseline	0.8836	Ingen
JPEG Compression	0.8440	Tydlig



WEAK/STRONG AUGMENTATION




Weak augmentation:

Fördelar:

- mer varierad träningsdata
- kan minska risken för overfitting

Nackdelar:

- lägre accuracy än baseline



Strong augmentation:

Nackdelar:

- bilderna kan bli orealistiska
- viktig information kan försvinna
- lägre accuracy i vårt experiment

RESULTAT

Experiment	Test Accuracy ↑	Test Loss ↓	Effekt
Baseline	0.8836	0.347241	Baseline
Normalisering (/255)	0.9008	0.273843	Stabilare träning
Standardisering	0.8994	0.294210	Mindre förbättring än normalisering
Låg upplösning (16x16)	0.8649	0.358299	Informationsförlust
Center crop (24x24)	0.8809	0.311160	Liten påverkan på resultatet
Compressed (JPEG q=50)	0.8440	0.459689	Brus (försämrade bildkvalitet)
Weak augmentation	0.7500	0.690595	Ingen tydlig förbättring av accuracy
Strong augmentation	0.4670	1.457134	Kraftigt försämrade resultat (orealistiska bilder)

* ↑ högre värde är bättre, ↓ lägre värde är bättre

SLUTSATSER

- Vi undersökte hur preprocessing påverkar deep learning-modeller. Våra resultat visar att rätt preprocessing både förbättrar accuracy och gör träningen stabilare.
 - Preprocessing påverkar modellen mycket, samma modell kan ge olika resultat beroende på input.
 - Normalisering hade störst positiv effekt och minskade även overfitting.
 - Bildkvalitet är viktig: När information försvann försämrades modellen.
 - Mer augmentation är inte alltid bättre: För stark augmentation kan göra datan (bilderna) orealistisk.
 - Vi lärde oss att preprocessing inte bara förbereder datan, det påverkar direkt hur modellen lär sig att tolka bilderna.
 - **Nästa steg:** Testa fler kombinationer av preprocessing, till exempel normalisering + weak augmentation samtidigt, testa fler epoker och testa andra modeller.
-